

## 1. Introduction

### 1.1. What is machine learning?


컴퓨터 프로그램은  $P$ 로 측정된  $T$ 의 작업 성능이 경험  $E$ 를 통해 향상되는 경우 작업  $T$  및 성능 측정  $P$ 의 일부 클래스와 관련하여 경험  $E$ 에서 학습한다고 한다.

머신러닝에는  $P, T, E$ 의 특성에 따라 다양한 분야 존재 ( $P$ : 시스템 평가하는데 쓰는 성능 척도,  $E$ : 훈련하는 경험,  $T$ : 시스템이 학습하기를 원하는 작업)

**probabilistic perspective** : 알려지지 않은 것을 확률로 분석

**random variables** : 랜덤 변수  $X$ 는 표본 공간에서 각 결과  $s$ 에 대해 실수  $x$ 를 할당하는 함수

**probability distributions** : 확률변수가 특정한 값을 가질 확률을 나타내는 함수



머신러닝은 불확실성안에서 확률에 의한 의사 결정을 하는 것..

### 1.2. Supervised Learning

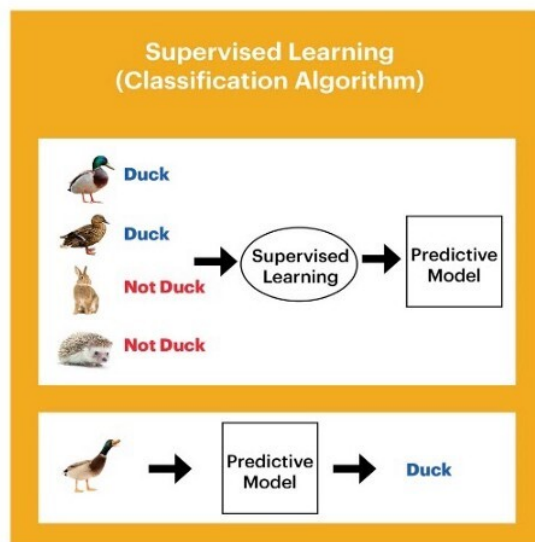
머신러닝에서 가장 흔한 형태가 Supervised Learning 지도학습.

지도 학습은 입력 데이터 각각에 대한 정답 (label 또는 class)이 함께 주어짐.

label이 있는 입출력 쌍이 주어졌을때 입력  $x$ 로 출력  $y$ 를 매핑하는 함수를 학습하는 것이 목표.

입력  $x$ 는  $D$ 차원 벡터로 특징(feature), 속성(attribute), 공변량(covariance)라고 함

출력  $y$ 는 한정된 값을 갖는 범주형 변수( 범주형인 경우 분류 classification라 함) , 실수 값을 갖는 스칼라 변수(실수인 경우 회귀 regression라 함)가 있다.



#### 1.2.1. Classification

분류의 목적은 입력  $x$ 로 부터 출력  $y$ 를 매핑하는 것을 학습하는 것으로,  $y$ 는  $1 \sim C$  값을 가지며  $C$ 는 class의 개수를 의미한다.  $C=2$ 인 경우엔 binary classification 이라 하고  $c>2$ 면 multiclass classification이라고 한다. 훈련 데이터에 대해 학습을 하고 예측을

하는건 쉽기 때문에 **classification**의 주요 목적은 전에 보지 못했던 데이터에 대해서도 답을 정확히 예측하는 것 (**Generalization**)이다.  
응용 분야 예시 (꽃 분류, 얼굴 검출 및 인식, 이미지 분류와 글씨 인식, 문서 분류와 이메일 스팸 필터링)

### 1.2.2. Regression

회귀는 결과 변수가 연속적이라는 것을 제외하고 **Classification**과 같다.


응용 분야 예시( 현재 시장 상황과 다른 가능한 정보를 통해 다음날의 주식 시장 예측, 유튜브를 보는 사용자의 나이 예측, 날씨 데이터와 시간을 통해 건물 안의 온도를 예측하는 것)

**MSE** 평균 제곱 오차 : 오차를 제곱한 값의 평균 .(오차 = 알고리즘이 예측한 값과 실제 정답과의 차이) **MSE**값이 작을수록 알고리즘의 성능이 좋다고 볼 수 있음.

#### 1.2.2.1. Linear regression

회귀에서는 선형 회귀라고 알려진 것을 주로 사용한다. 선형 회귀란 데이터를 가장 잘 대변하는 최적의 선을 찾는 과정 .  $x$ 는 변수, 기울기  $w$ 는  $a$ , 절편  $b$ .

선형회귀에서는 **MSE**를 최소화하는 방법으로 가중치(기울기)와 절편을 구할 수 있다.




#### 1.2.2.2. Polynomial regression

다중 회귀 분석 : 데이터를 표현함에 있어 선형이 아닌 곡선으로 나타나는 경우에 사용하는 회귀.

### 1.2.3. Overfitting and generalization

**overfitting** : 유연한 모델을 만들기 위해서 과적합 하지 않도록 주의해야 한다. 입력의 모든 변화를 모형화하는것은 피해야한다는 것.. 모든 변화를 모형화할수록 노이즈인 경우가 많이 때문.

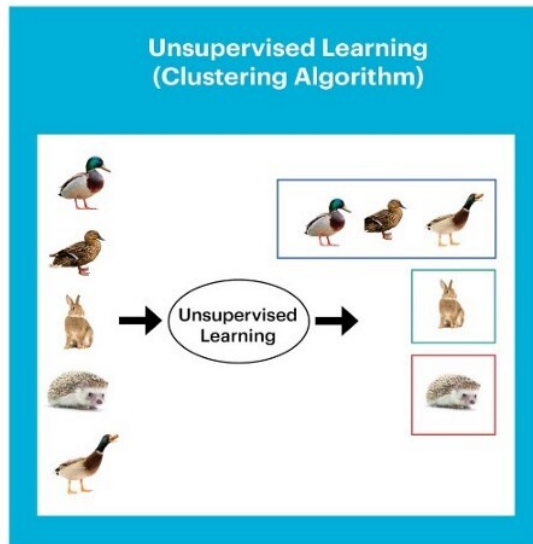


<< 모든 변화를 모형화함

### 1.2.4. No free lunch theorem

공짜 점심은 없다! .. 특정 문제에 대해서 최적화할 수 있지만 모든 문제에 대해 최적의 모델은 없다. 인공지능에서는 모든 문제에 적용할 수 있는 무적의 특정한 알고리즘은 없다는 의미. 하나의 영역에서 잘 작동하는 가정이 다른 영역에서 잘못 작동하는 경우가 있다는 것.

### 1.3. Unsupervised Learning




Western Digital.

비지도 학습은 모델의 입력값으로 입력 데이터만 주어짐. 정답이 없는 모델을 모델에게 요구하는 것. 데이터 분석을 통해 **unknown pattern**을 학습할 수 있게 되고 새로운 데이터가 입력으로 주어졌을때 분류할 수 있게 되는 것. 데이터간의 유사도, 패턴, 차이 등으로 데이터를 분류할 수 있는 학습을 진행하는 것.

#### 1.3.1. Clustering

비지도학습의 기본이 되는 예제로 데이터를 그룹으로 **clustering**하는 문제이다.



#### 1.3.2. Discovering latent “factors of variation”

데이터가 엄청 복잡한 경우에는 데이터를 통한 학습이 어려울 수 있다. 노이즈(불량) 데이터를 제거하여 단순화함으로써 학습을 쉽게하고 데이터에서 의미있는 인사이트를 찾을 수 있다. 잠재 변수 모델은

데이터 전처리 단계에서 큰 도움이 된다. 차원 축소를 위한 가장 일반적인 접근은 PCA (주성분 분석)이다.

### 1.3.3. Self-supervised learning

자기지도 학습이란 레이블이 없는 데이터로부터 학습하는 기법. 레이블이나 주석이 필요하지 않은 대신 데이터 자체에서 학습 과제를 생성함. 예를 들어 이미지에서 일부를 가리고 모델이 가려진 부분을 예측하게 하는 것이 자기지도 학습의 한 예시.

### 1.3.4. Evaluating unsupervised learning

## 1.4. Reinforcement Learning

강화학습이란 시행착오 (Trial and Error) 를 통해 학습하는 방법. 실수와 보상을 통해 학습을 하여 목표를 찾아가는 알고리즘. **action**에 따른 경험 그 자체를 학습의 원천으로 활용..

## 1.5. Data

- 1.5.1. Some common image datasets
- 1.5.2. Some common text datasets
- 1.5.3. Preprocessing discrete input data
- 1.5.4. Preprocessing text data
- 1.5.5. Handling missing data

## 1.6. Discussion

- 1.6.1. The relationship between ML and other fields
- 1.6.2. Structure of the book
- 1.6.3. Caveats